


Construire une infrastructure nationale FAIR des données sols au service du PEPR SolsVivants



1

Linda Angulo Lopez

PEPR SolsVivants – France 2030 / ANR • INRAE / CNRS / AGRALIFE

9 M€

Budget sur 5 ans

2 projets

Ciblés (PC1 & PC2)

4 axes

Animation transverse

Contexte scientifique & enjeux



Le PEPR SolsVivants

Programme co-piloté INRAE / CNRS

Budget : 9 M€ sur 5 ans (France 2030 / AGRALIFE)

Démarrage 2026 – webinaire de lancement le 6 juillet

2 projets ciblés : réseaux d'interactions dans les sols ; impact des interactions biotiques sur la multifonctionnalité

4 axes transverses : multi-taxa, empirique ↔ théorie, scénarios de changement, tempéré ↔ tropical

Fonctions-clés des sols



Cycles C / N / P



Structuration & transfert d'eau



Microbiome & biodiversité




Réseaux trophiques & interactions



Multifonctionnalité à toutes échelles

 **Enjeu central : passer de données fragmentées à une infrastructure intégrée des sols vivants**

Feuille de route



Court terme

0 – 12 mois

- › Cartographie des données PEPR (inventaire & types)
- › Alignement avec GBIF / Data Terra / THEIA (métadonnées) / ISRIC · LUCAS
- › PGD commun PEPR + système de versioning (Opidor)
- › Prototype plateforme PEPR (MVP)
- › 1er atelier communauté — formation FAIR data
- › Réseau de data stewards (1 par projet ciblé)

Moyen terme

1 – 3 ans


- › Plateforme FAIR pleinement opérationnelle
- › Interopérabilité GIS Sol + THEIA + PEPR effective
- › Pipelines multi-omics standardisés & documentés
- › Premières synthèses scientifiques intégrées
- › Indicateurs de santé des sols v1
- › 2 hackathons soil data + ateliers inter-projets

Long terme


3 – 5 ans

- › Infrastructure nationale intégrée des données sols
- › Intégration dans systèmes de monitoring environnemental
- › Indicateurs opérationnels → contribution politiques publiques
- › Nœud européen de référence (European Soil Mission, ISRIC)
- › Architecture réutilisable pérenne après le PEPR

Positionnement stratégique: sources des données

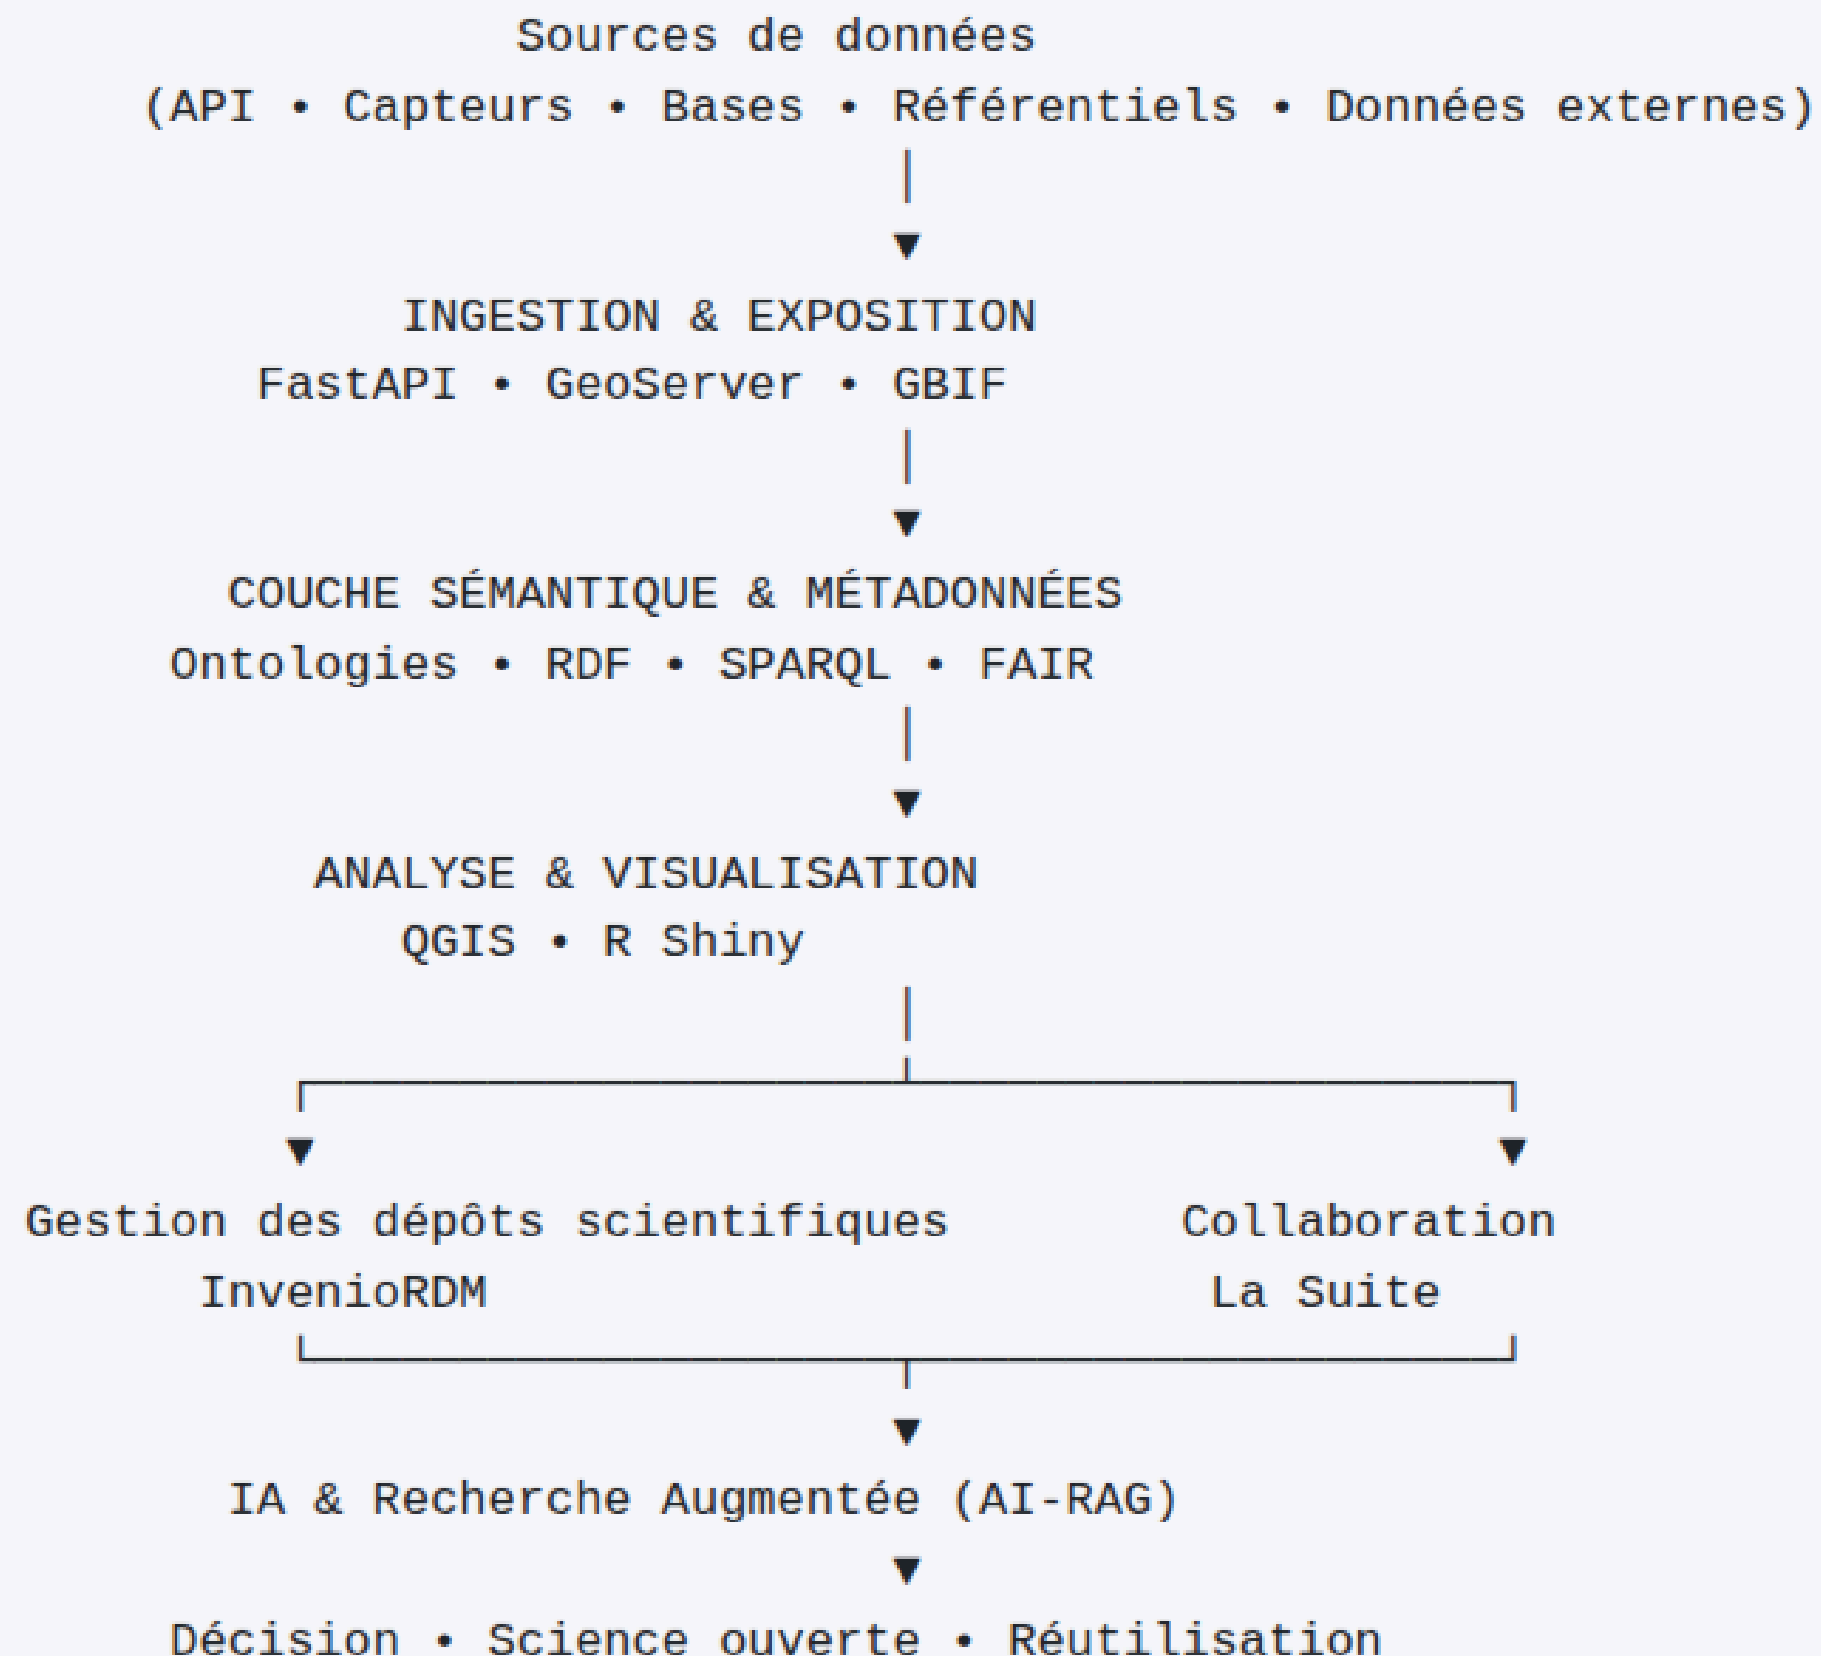



Le PEPR n'ajoute pas une base de données — il complète une architecture nationale existante



Message clé : fédérer sans centraliser — connecter des écosystèmes, pas créer des silos


Architecture fédérée de la plateforme de données



Objectif : construire une plateforme fédérée, interopérable et évolutive permettant de collecter, enrichir, analyser, diffuser et valoriser les données scientifiques selon les principes FAIR.

Couches complémentaires: chacune répondant à une fonction spécifique du cycle de vie des données scientifiques.

- Couche d'ingestion & exposition
- Analyse, diffusion et services
- Couche sémantique & graphe de connaissances



Couche d'ingestion & exposition

Objectif :

- disposer d'une base de données interopérable, standardisée et exploitable.

Défis:

- ingestion multi-sources (API, capteurs, référentiels, bases)
- structuration selon des standards ouverts (OGC, Darwin Core)
- exposition via API REST et services géospatiaux

Options:

- **FastAPI** : faciliter l'intégration entre systèmes
- **GeoServer**: garantir l'interopérabilité avec les clients SIG
- **GBIF**: favoriser la réutilisation scientifique

Analyse, diffusion et services



Objectif :


- transformer les données en connaissances exploitables par les chercheurs et les partis prenant.

Défis:

- Couche d'analyse & services analyse spatiale et statistique visualisation interactive dépôt et diffusion FAIR collaboration scientifique

Options:

- **QGIS / ipynb**: produire des cartes et des analyses expertes
- **RShiny**: explorer les données en temps réel
- **InvenioRDM**: attribuer des DOI et gérer les métadonnées FAIR et diffuser les objets de recherche via des API
- **La Suite**: renforcer l'interopérabilité des services publics
- **AI-RAG**: interroger les données en langage naturel et enrichir les réponses à partir des sources internes



Couche sémantique & graphe de connaissances

Objectif :


- transformer une plateforme de données en plateforme de connaissances

Défis:

- interopérable, FAIR et exploitable par l'intelligence artificielle.
- expliquer l'origine des informations grâce à la traçabilité
- contextualiser les réponses de l'IA

Options:

- **RDF / SPARQL** : interroger plusieurs sources de manière unifiée
- **Ontologies scientifiques**: préserver le sens des données
- **Knowledge Graph & AI-RAG**: combiner documents, données et relations sémantiques
- **Couche sémantique**: fondation d'un graphe de connaissances scientifique




Principe d'articulation de l'architecture

L'architecture s'organise en couches complémentaires

- **Sources** > Sources françaises et internationales
- **Ingestion & exposition** > FastAPI • GeoServer • GBIF
- **Interopérabilité sémantique** > RDF • SPARQL • Ontologies
- **Analyse & visualisation** > QGIS • R Shiny
- **Gestion des dépôts scientifiques** > InvenioRDM
- **Services collaboratifs** > La Suite
- **Intelligence augmentée** > AI-RAG

Sources de données → Ingestion → Interopérabilité sémantique → Analyse →
Diffusion scientifique → Collaboration → Intelligence augmentée

Besoins de formation



Court terme

(0–3 mois / 35 JH)

- › Conception d’une architecture fédérée (data mesh / API-first / infrastructures scientifiques) :
- › Mise en place des bases de modélisation sémantique (knowledge graphs, ontologies)
- › Définition des standards d’interopérabilité (INSPIRE, ISO, STAC, FAIR)
- › Structuration de workflows scientifiques reproductibles (Nextflow, Docker, provenance)
- › Production d’un MVP d’architecture cible PEPR

Moyen terme


(3–12 mois / 30 JH)

- › Mise en place d’une fédération de données via API distribuées
- › Construction d’un knowledge graph national opérationnel sur les sols
- › Standardisation des pipelines multi-omics et environnementaux
- › Intégration des traitements géospatiaux scalables (STAC, xarray, cloud)
- › Alignement avec les infrastructures nationales et européennes (Data Terra, THEIA, GBIF)

Long terme

(12–24 mois / 15 JH)

- › Contribution aux Digital Public Infrastructures (DPI) et data spaces européens
- › Mise en place d’une approche “policy-as-code” pour la gouvernance FAIR
- › Automatisation de la gouvernance des données et des règles d’usage
- › Prise en compte des dynamiques socio-institutionnelles et de l’adoption




Ma vision : 5 piliers d'action

1



Gouvernance
& PGD

2



Standards &
Interopérabilité

3



Infrastructure
FAIR intégrée

4



Données →
Connaissances


5



Animation
scientifique

→ *Un continuum cohérent du plan de gestion jusqu'à la valorisation scientifique*

Principe directeur : FAIR by design · interopérabilité native · co-construction avec la communauté



Pilier 1 — Gouvernance & Plan de Gestion des Données

1 PGD harmonisé PEPR SolsVivants

Un PGD vivant, compatible Data Terra / THEIA, intégrant les exigences ANR et France 2030. Révisé annuellement avec les équipes projets.

2 Rôles et responsabilités clairs

Producteurs de données · Data stewards par projet · Coordination nationale. Chaque rôle est formalisé dès le démarrage.

3 Licences & accès aux données

Choix de licences ouvertes (Licence Etalab LO, CC-BY, ODbL), gestion des données sensibles, politique d'embargo raisonnée (max 12 mois).

8

4 PGD = outil de pilotage scientifique

Pas un document administratif figé, mais un outil de dialogue entre coordinateurs, chercheurs et entités de financement.



Pilier 2 — Standards & Interopérabilité


Alignement stratégique :

THEIA	Métadonnées, catalogues, vocabulaires
GIS Sol	Référentiels pédologiques
ISO / INSPIRE	Standards européens
Ontologies	AgroPortal, ENVO, NCBI, standards MlxS/GSC, ECOCORE, approches par traits fonctionnels
Harmoniser	Métadonnées PNDB et le pôle THEIA avec e-LTER, INPN, NCBI, BOLD Systems

Actions concrètes :

- ✓ Standards minimaux d'échantillonnage communs à tous les projets PEPR
- ✓ Harmonisation des séquençages (16S, ITS, shotgun) → pipelines partagés
- ✓ Vocabulaire contrôlé commun (thésaurus THEIA + extensions sols vivants)
- ✓ Templates de métadonnées prêts à l'emploi pour les équipes terrain
- ✓ Revues régulières de conformité avec les data stewards

Standardiser les formats et les métadonnées — pas les pratiques scientifiques



Pilier 3 — Infrastructure FAIR intégrée

Observation & télédétection

GIS Sol · THEIA · Climat

Biodiversité des sols

PEPR SolsVivants (microbiome · faune · protistes)

Fonctions écosystémiques

Cycles C/N/P · structure · hydrologie · services

10



Interopérabilité bi-directionnelle · API ouvertes · DOI par jeu de données



Plateforme fédérée

Interopérable GBIF / Data Terra / THEIA · pas de silo



API ouvertes + versioning

Toutes les données citables (DOI) · traçabilité




Multi-sources intégrées

Sols · télédétection · biodiversité · climat

Principe : « one data ecosystem – multiple infrastructures connectées »



Pilier 4 — Données → Connaissances



Liens biodiversité ↔ fonctions des sols

Pipelines multi-omics standardisés (16S, ITS, shotgun) intégrant traits fonctionnels et activité enzymatique.

Cycles biogéochimiques intégrés

Synthèses C / N / P reliant données omiques, mesures terrain et modèles de fonctionnement.

Indicateurs de santé des sols

11

Co-construction avec GIS Sol et RMT Sols & Territoires → indicateurs opérationnels pour les politiques publiques.


Gestion explicite des incertitudes

Séparation claire observé / inféré / mesuré. L'incertitude devient un objet scientifique à part entière.

Ambition : transformer les données THEIA / PEPR en compréhension écologique intégrée et actionnée



Pilier 5 — Animation scientifique nationale



Partenaires & articulation

AFES Communauté scientifique pédologie

GIS Sol Expertise & référentiels sols

RMT Sols & Territoires Acteurs terrain & gestion

GBIF / Data Terra / THEIA Infrastructures de données

LUCAS Soil / European Soil Mission Dimension européenne

12


Actions concrètes



Formations FAIR data pour les équipes terrain



Ateliers inter-projets PEPR (2×/an)



Hackathons soil data — valorisation collaborative



Réseau national de data stewards de proximité



Connexion aux initiatives européennes (ISRIC, Pedometrics, LUCAS Soil)



Défis, limites & réponses anticipées



Risque

Hétérogénéité des données & méthodes



Réponse

Socle minimal de métadonnées obligatoire + recommandations souples. Standardiser les formats, pas les pratiques.



Risque

Adoption par la communauté



Réponse

Retour direct d'usage (visualisation, analyses). DOI par jeu de données. Data stewards de proximité.



Risque

Surinterprétation taxon → fonction



Réponse

Séparation observé / inféré / mesuré. L'incertitude devient un objet scientifique à part entière.



Risque

Pérennité après le PEPR



Réponse

Adossement Data Terra / THEIA / INRAE. Standards ouverts. Architecture réutilisable dès le départ.



Risque

Fragmentation des initiatives



Réponse

Plateforme fédérée. Gouvernance nationale des standards. Interopérabilité obligatoire sur métadonnées.

13



Conclusion



Structurer des données aujourd'hui fragmentées en une infrastructure cohérente



Connecter biodiversité et fonctions des sols (couche biologique manquante)



S'intégrer dans les infrastructures nationales (GBIF / Data Terra / THEIA / GIS Sol)

14




Produire une infrastructure durable, réutilisable et pérenne au-delà du PEPR

Mon objectif : construire une infrastructure de données sols scientifique, interopérable et utile — qui transforme les données en connaissances actionnables pour la recherche et les politiques publiques.

Merci

Questions & échanges



Linda Angulo Lopez
angulo.linda@gmail.com

15

pepr-solsvivants.fr · data-terra.org · theia-land.fr · gissol.fr

European Soil Mission · ISRIC · LUCAS Soil · Pedometrics