

1

Bonjour, je suis Linda Angulo Lopez. Je vais vous présenter ma vision pour structurer, animer et développer la gestion des données au sein du PEPR SolsVivants. Je structurerai mon propos en trois parties : contexte et positionnement, les 5 piliers d'action, puis une feuille de route court/moyen/long terme.

Page 2 - Contexte scientifique & enjeux

2

Le PEPR SolsVivants vient de démarrer en 2026. Son ambition est de comprendre les interactions dans les sols pour agir. Les données générées seront d'une grande hétérogénéité : multi-taxa, multi-échelles, multi-omiques. Mon rôle sera de les rendre comparables, réutilisables et actionnables.

Page 3 - Feuille de route

3

La feuille de route est organisée en trois horizons. À court terme, l'enjeu est de poser les fondations. À moyen terme, de rendre l'infrastructure opérationnelle et de produire les premières synthèses. À long terme, de pérenniser et de rayonner à l'échelle européenne.

Page 4 - Positionnement stratégique: sources des données

4

Le véritable enjeu du PEPR SolsVivants n'est pas de créer une nouvelle base de données, mais de fédérer les infrastructures existantes. Le PEPR constitue le pont fonctionnel entre des plateformes comme Data Terra, THEIA et GIS Sol.

Pour construire cette architecture, j'adopte une approche en trois niveaux : **les systèmes**, **les flux de données** et **les transformations**. J'identifie d'abord les systèmes et leurs interfaces, puis je cartographie les flux de manière indépendante afin de clarifier les responsabilités. Enfin, je documente les transformations appliquées aux données (harmonisation, enrichissement, contrôle qualité, traçabilité).

Je privilégie une démarche itérative : commencer par les workflows scientifiques prioritaires et les intégrations à forte valeur ajoutée, puis étendre progressivement la cartographie en fonction des risques, des dépendances et des besoins métiers. Cette approche garantit une architecture évolutive, interopérable et conforme aux principes FAIR.

Page 5 - Architecture fédérée de la plateforme de données

5.

Dans PEPR SolsVivants, je vois l'écosystème comme une **chaîne de valeur de la donnée vers la connaissance**, et non comme un ensemble de plateformes indépendantes. L'objectif est de garantir la traçabilité, l'interopérabilité et la réutilisation des données selon les principes FAIR.

L'architecture repose sur cinq couches complémentaires. La première assure **l'ingestion et l'exposition** des données via des API et des standards ouverts. La deuxième permet **l'analyse et la visualisation** des données scientifiques. La troisième apporte **l'interopérabilité sémantique**, grâce aux ontologies, à RDF et à SPARQL, pour construire un graphe de connaissances. La quatrième gère **la diffusion des données et des productions scientifiques** avec InvenioRDM. Enfin, les services collaboratifs et **l'IA-RAG** permettent une exploration intelligente, contextualisée et traçable.

Cette architecture fédérée transforme des données distribuées en connaissances exploitables pour la recherche et l'aide à la décision.

Page 6 - Couche d'ingestion & exposition

6.

Cette première couche assure **l'ingestion et l'exposition des données** en connectant des sources hétérogènes et en les rendant accessibles selon des standards ouverts.

FastAPI centralise l'exposition des services via des API REST. **GeoServer** diffuse les données géospatiales selon les standards OGC pour garantir leur interopérabilité avec les outils SIG. **GBIF** facilite l'intégration des données de biodiversité en s'appuyant sur des standards internationaux comme Darwin Core.

L'objectif est de collecter des données provenant de multiples sources (API, capteurs, référentiels, bases existantes), de les normaliser et de les exposer de manière homogène afin de disposer d'un socle de données interopérable, fiable et directement exploitable par les chercheurs et les applications.

Page 7 - Analyse, diffusion et services

7.

Cette couche transforme les données en **connaissances exploitables**. **QGIS** ou ipynb permet l'analyse spatiale et la production de cartographies, tandis que **R Shiny** offre des tableaux de bord interactifs pour explorer et valoriser les résultats.

Les données et productions scientifiques sont ensuite gérées et diffusées via **InvenioRDM**, qui assure le dépôt, le versionnement, l'attribution de DOI et la conformité aux principes FAIR. **La Suite** apporte les outils collaboratifs nécessaires au travail des équipes de recherche. Enfin, **AI-RAG** permet d'interroger les données et les documents en langage naturel en s'appuyant sur les connaissances de la plateforme.

L'objectif est de fournir un environnement intégré où les données sont analysées, partagées, diffusées et enrichies afin de soutenir efficacement la recherche et l'aide à la décision.

8.

Cette couche apporte **l'interopérabilité sémantique** en transformant les données en un **graphe de connaissances**. Grâce à **RDF**, les données, métadonnées, observations, publications et objets de recherche sont reliés entre eux, tandis que **SPARQL** permet de les interroger de manière unifiée, même lorsqu'elles proviennent de plateformes différentes.

Les **ontologies scientifiques** harmonisent les vocabulaires et préservent le sens des données, garantissant leur cohérence et leur réutilisation selon les principes FAIR.

Enfin, le **Knowledge Graph**, combiné à **AI-RAG**, permet d'exploiter simultanément les données, les documents et leurs relations sémantiques. Les réponses de l'IA deviennent ainsi plus précises, contextualisées et traçables.

L'objectif est de faire évoluer une plateforme de données vers une **plateforme de connaissances**, interopérable et directement exploitable par la recherche et l'intelligence artificielle.

Page 9 - Principe d'articulation de l'architecture

9.

L'architecture est organisée en **couches fonctionnelles complémentaires**, formant une chaîne de valeur continue allant des données vers la connaissance. Elle s'appuie sur des **sources de données françaises et internationales**, intégrées via une couche d'**ingestion et d'exposition** reposant sur FastAPI, GeoServer et GBIF. Ces données sont ensuite enrichies par une couche d'**interopérabilité sémantique** fondée sur RDF, SPARQL et les ontologies, permettant de relier et structurer les informations. La couche d'**analyse et de visualisation** (QGIS, R Shiny) permet leur exploitation scientifique, tandis que la **diffusion des productions** est assurée par InvenioRDM. Les **services collaboratifs** sont fournis par La Suite, et l'**intelligence augmentée** repose sur des approches AI-RAG.

Cette organisation vise à construire une **plateforme nationale de connaissances scientifiques**, fédérée, interopérable et conforme aux principes FAIR, transformant les données en connaissances exploitables pour la recherche, l'expertise et l'aide à la décision.

Page 10 - Besoins de formation

10.

Ce plan de **80 jours-homme** vise à faire évoluer la posture d'une simple gouvernance FAIR et SIG vers celle d'un **architecte d'une infrastructure fédérée de données scientifiques sur les sols vivants**, à l'échelle du PEPR.

À **court terme**, il s'agit de poser les bases conceptuelles et architecturales : clarifier le système, structurer les flux de données et définir un **modèle sémantique cohérent des sols vivants**. À **moyen terme**, l'objectif est de stabiliser cette architecture en la rendant opérationnelle, interopérable et alignée avec les principaux écosystèmes existants. À **long terme**, le but est de contribuer à la construction d'une **infrastructure publique pérenne**, capable de soutenir un modèle européen durable de production, partage et valorisation des données scientifiques.

L'ensemble s'inscrit dans une logique progressive : passer de la conception à la structuration, puis à la consolidation d'une infrastructure scientifique robuste et durable.

Page 11 - Ma vision : 5 piliers d'action

11

Je vais maintenant détailler chacun de ces 5 piliers. Ils sont conçus comme un continuum : la gouvernance fonde les standards, les standards permettent l'infrastructure, l'infrastructure produit des connaissances, et l'animation assure que tout cela vit dans la communauté.

Page 12 - Pilier 1 — Gouvernance & Plan de Gestion des Données

12

Le PGD n'est pas une formalité administrative. C'est l'outil central qui fonde toute la gouvernance des données. Je veillerai à ce qu'il soit co-construit avec les équipes, réaliste et évolutif.

Page 13 - Pilier 2 — Standards & Interopérabilité

13

L'interopérabilité ne s'improvise pas. Elle se construit dès le début, avec des standards explicites et des outils concrets mis à disposition des équipes. L'enjeu n'est pas de contraindre les chercheurs, mais de leur faciliter la vie tout en garantissant la comparabilité.

Page 14 - Pilier 3 — Infrastructure FAIR intégrée

14

L'architecture cible est une plateforme PEPR qui s'interface nativement avec Data Terra et THEIA. Chaque jeu de données reçoit un DOI, les APIs sont ouvertes, et la traçabilité des versions est garantie. La difficulté n'est pas de stocker les données, mais de les rendre comparables et réutilisables.

Page 15 - Pilier 4 — Données 8 Pilier 4 — Données Connaissances

15

Le PEPR doit aller au-delà du stockage de données. Mon objectif est de mettre en place des pipelines qui permettent de passer des données brutes à des indicateurs scientifiquement robustes et utiles pour les décideurs.

Page 16 - Pilier 5 — Animation scientifique nationale

16

La donnée doit être utile pour être partagée. Mon action d'animation vise à créer les conditions sociales de cette utilité : des formations accessibles, des espaces de rencontre entre projets, et des

data stewards de proximité qui accompagnent les équipes terrain.

Page 17 - Défis, limites & réponses anticipées

17

Anticiper les risques est crucial pour un projet de cette envergure. Dans ce projet, ces cinq défis pourraient se présenter.

Page 18 - Conclusion

18

Pour conclure, le PEPR SolsVivants est une opportunité unique pour combler le chaînon manquant entre les grandes infrastructures de données environnementales et la compréhension biologique et fonctionnelle des sols. Je suis convaincue que ce projet, à ce moment précis, peut faire de la France un point de référence européen pour les données sur les sols vivants.

Page 19 - Questions & échanges

Je voudrais conclure en soulignant que la valeur ajoutée d'une ingénieure cheffe de projet données ne réside pas uniquement dans la maîtrise technique, mais dans la capacité à comprendre les enjeux scientifiques, à animer des communautés et à prendre des décisions pragmatiques.

Dans un écosystème fédéré comme PEPR SolsVivants, les flux de données ne sont pas seulement des échanges entre systèmes : ils reflètent aussi des dépendances, des choix organisationnels et des pratiques socio-techniques. L'enjeu principal de l'interopérabilité n'est pas tant l'absence de standards que l'existence de nombreux usages informels — fichiers Excel, scripts locaux, conventions de laboratoire — souvent invisibles mais essentiels.

L'objectif est donc de rendre ces pratiques explicites, pour les intégrer progressivement dans une architecture FAIR, sans perturber les usages scientifiques existants.

Je vous remercie pour votre attention et je suis prête à répondre à vos questions.